

# RoPE

Qwen3.5 源码解析

RoPE (Rotary Position Embedding) 通过旋转 Q/K 特征，使 attention 内积包含相对位置信息。设旋转维度为偶数  $d_r$ ，频率底数为  $\beta$ ，位置为  $p$ ；第  $i$  个二维子空间的角频率与旋转角为

$$\omega_i = \beta^{-2i/d_r}, \quad \phi_{p,i} = p\omega_i, \quad i = 0, \dots, \frac{d_r}{2} - 1.$$

- $\beta$  对应 `rope_theta`，源码变量名为 `base`，是生成频率序列的底数
- 当  $\beta > 1$  时，频率以公比  $\beta^{-2/d_r}$  递减： $\omega_0 = 1$ ，后续频率逐渐降低。增大 `base` 会拉长  $i > 0$  各分量的周期  $2\pi/\omega_i$
- `inv_freq[i]` 表示第  $i$  对旋转特征每单位位置的相位增量，实际旋转角为 `position_id * inv_freq[i]`

```
{
  "text_config": {
    "hidden_size": 5120,
    "num_attention_heads": 24,
    "num_key_value_heads": 4,
    "head_dim": 256,
    "max_position_embeddings": 262144,
    "rope_parameters": {
      "rope_type": "default",
      "rope_theta": 100000000,
      "partial_rotary_factor": 0.25,
      "mrope_interleaved": true,
      "mrope_section": [11, 11, 10]
    }
  }
}
```

源码采用 [B,H,T,d\_h] 布局：B 为 batch size，T 为当前输入长度，Q/K 的 head 数分别为 24/4；head\_dim 为  $d_h = 256$ ，旋转比例  $r = 0.25$ ，故  $d_r = \lfloor d_h r \rfloor = 64$

|              |                                                                                |
|--------------|--------------------------------------------------------------------------------|
| Q / K        | [B, 24, T, 256] / [B, 4, T, 256]                                               |
| position_ids | [B, T]                                                                         |
| inv_freq     | [32]                                                                           |
| 相位 $\Phi$    | [B, T, 32]                                                                     |
| cos / sin    | [B, T, 64] $\rightarrow$ <code>unsqueeze(1)</code> $\rightarrow$ [B, 1, T, 64] |

先由 `Qwen3_5TextRotaryEmbedding.compute_default_rope_parameters()` 计算 32 个频率：

```
base = config.rope_parameters["rope_theta"]
partial_rotary_factor = config.rope_parameters.get("partial_rotary_factor", 1.0)
head_dim = getattr(config, "head_dim", None) or config.hidden_size // config.num_attention_heads
dim = int(head_dim * partial_rotary_factor)

attention_factor = 1.0
inv_freq = 1.0 / (base ** (torch.arange(0, dim, 2, dtype=torch.float) / dim))
return inv_freq.to(device), attention_factor
```

- `arange(0,64,2)/64` 生成指数  $[0, 1/32, \dots, 31/32]$ , 得到 `inv_freq` 为  $[1, 10^{-7/32}, \dots, 10^{-217/32}]$
- 频率按旋转维度 64 直接计算, 而非从全维 RoPE 中截取

RoFormer §3.2.1 式 (13) 先给出二维形式。只写 Q 分支, 以  $\mathbf{q}_m$  表示旋转前的 Q、 $\tilde{\mathbf{q}}_m$  表示旋转后的 Q:

$$\begin{aligned}\tilde{\mathbf{q}}_m &= f_q(\mathbf{x}_m, m) \\ &= \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix} \begin{bmatrix} W_q^{(11)} & W_q^{(12)} \\ W_q^{(21)} & W_q^{(22)} \end{bmatrix} \begin{bmatrix} x_m^{(1)} \\ x_m^{(2)} \end{bmatrix} \\ &= R(m\omega)\mathbf{q}_m, \quad \mathbf{q}_m = W_q\mathbf{x}_m.\end{aligned}$$

- 从右向左计算: 输入  $\mathbf{x}_m$  先经  $W_q$  投影得到  $\mathbf{q}_m$ , 再乘旋转矩阵得到  $\tilde{\mathbf{q}}_m$ 。角频率统一记为  $\omega$ , 对应前文某一通道对的  $\omega_i$ ;  $m\omega$  是位置乘频率
- 对应到 Qwen3.5, 取一个 token、一个 head 传入 RoPE 的 Q 向量  $\mathbf{q}$  (已完成投影和 Q norm)。设位置  $p = 1$ ,  $\mathbf{q}[0]=1$ 、 $\mathbf{q}[32]=2$ ; 这对通道的频率  $\omega_0 = 1$ , 因此:

$$\begin{bmatrix} \tilde{q}_0 \\ \tilde{q}_{32} \end{bmatrix} = \begin{bmatrix} \cos 1 & -\sin 1 \\ \sin 1 & \cos 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} \approx \begin{bmatrix} -1.142640 \\ 1.922076 \end{bmatrix}.$$

- 结果已经是旋转后 Q 的第 0、32 维。其余 31 对同样计算, 再接回未旋转的后 192 维, 得到完整的  $\tilde{\mathbf{q}}_p = \hat{R}_p \mathbf{q}_p \in \mathbb{R}^{256}$ ;  $\hat{R}_p$  的完整矩阵见下文。K 同理, 随后用旋转后的 Q/K 计算 attention 内积。同一 token 的各 head 复用 cos/sin, 分别旋转各自的 Q/K 数值

RoFormer 式 (15) 对全部  $d$  维旋转。令  $F = d/2$ 、 $\phi_i = p\beta^{-2i/d}$ , 以从 0 开始的索引写为:

$$R_p^{(d)} = \begin{pmatrix} \cos \phi_0 & -\sin \phi_0 & 0 & 0 & \cdots & 0 & 0 \\ \sin \phi_0 & \cos \phi_0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos \phi_1 & -\sin \phi_1 & \cdots & 0 & 0 \\ 0 & 0 & \sin \phi_1 & \cos \phi_1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos \phi_{F-1} & -\sin \phi_{F-1} \\ 0 & 0 & 0 & 0 & \cdots & \sin \phi_{F-1} & \cos \phi_{F-1} \end{pmatrix} \in \mathbb{R}^{d \times d}.$$

- 每个  $2 \times 2$  块作用于 Q 的相邻分量  $(q_{2i}, q_{2i+1})$ , K 同理; 整体为  $\text{diag}(R(\phi_0), \dots, R(\phi_{F-1}))$ 。式 (14) 定义  $\tilde{\mathbf{q}}_m = R_m^{(d)} W_q \mathbf{x}_m$ 、 $\tilde{\mathbf{k}}_n = R_n^{(d)} W_k \mathbf{x}_n$ ; 记投影结果为  $\mathbf{q}_m, \mathbf{k}_n$ , 由  $R_m^\top R_n = R_{n-m}$  得到相对位置内积:

$$\begin{aligned}\tilde{\mathbf{q}}_m^\top \tilde{\mathbf{k}}_n &= (R_m \mathbf{q}_m)^\top (R_n \mathbf{k}_n) \\ &= \mathbf{q}_m^\top R_m^\top R_n \mathbf{k}_n \\ &= \mathbf{q}_m^\top R_{n-m} \mathbf{k}_n.\end{aligned}$$

Qwen3.5 的 partial RoPE 是分块正交变换: 前 64 维参与旋转, 后 192 维由单位映射保留。令

$D_c(p) = \text{diag}(\cos \phi_{p,0}, \dots, \cos \phi_{p,31})$ 、 $D_s(p) = \text{diag}(\sin \phi_{p,0}, \dots, \sin \phi_{p,31})$ , 其中  $\phi_{p,i} = p\beta^{-2i/64}$ , 则

$$\hat{R}_p = \left( \begin{array}{cc|c} D_c(p) & -D_s(p) & 0 \\ D_s(p) & D_c(p) & 0 \\ \hline 0 & 0 & I_{192} \end{array} \right), \quad \tilde{\mathbf{q}}_p = \hat{R}_p \mathbf{q}_p, \quad \tilde{\mathbf{k}}_p = \hat{R}_p \mathbf{k}_p.$$

- 左上角的  $64 \times 64$  旋转块记为  $\mathcal{R}_p$ ，通过固定的通道置换与论文的块对角矩阵对应。旋转在 **attention** 内积之前分别作用于 Q 和 K，只在各自的成对通道内作线性组合，保持向量范数，不含平移项；旋转通道与保留通道之间没有交叉混合。
- 完整 head 在添加 mask 前的 attention score 因而分解为：

$$s_{mn} = \frac{(\mathbf{q}_m^{\text{rot}})^\top \mathcal{R}_{n-m} \mathbf{k}_n^{\text{rot}} + (\mathbf{q}_m^{\text{pass}})^\top \mathbf{k}_n^{\text{pass}}}{\sqrt{d_h}}.$$

- 第一项通过  $\mathcal{R}_{n-m}$  引入相对位置，第二项是保留通道的普通内积；两项共同构成 **attention score**，缩放分母仍为  $\sqrt{d_h} = \sqrt{256}$ 。完整的 256 维 K 均写入 cache

对普通 RoPE，位置张量为  $P \in \mathbb{Z}^{B \times T}$ ，其中  $P_{b,t}$  保存第  $b$  个样本中第  $t$  个 token 的位置编号。每个位置与 32 个频率分别相乘，得到该 token 的 32 个旋转角：

$$\Phi_{b,t,i} = P_{b,t} \omega_i, \quad \Phi \in \mathbb{R}^{B \times T \times (d_r/2)}, \quad C = [\cos \Phi, \cos \Phi], \quad S = [\sin \Phi, \sin \Phi].$$

- $\Phi$  保存旋转角，本例形状为  $[B, T, 32]$ ； $C$ 、 $S$  保存对应的 cos/sin 系数。方括号表示沿最后一维拼接，使  $C/S$  的形状成为  $[B, T, 64]$ ：第  $i$ 、 $i + 32$  个通道属于同一旋转对，因而需要相同的系数。  
`unsqueeze(1)` 再将系数变为  $[B, 1, T, 64]$ ，供同一 token 的所有 Q/K head 复用。
- 固定一个 token 和一个 head，记  $p = P_{b,t}$ 。源码将二维旋转矩阵的乘法展开为逐元素乘加，第  $i$ 、 $i + 32$  个通道的输出为：

$$\begin{aligned} \tilde{q}_i &= q_i \cos(p\omega_i) - q_{i+32} \sin(p\omega_i), \\ \tilde{q}_{i+32} &= q_i \sin(p\omega_i) + q_{i+32} \cos(p\omega_i), \quad i = 0, \dots, 31. \end{aligned}$$

- `rotate_half(q_rot)` 在这两个位置分别提供  $-q_{i+32}$  和  $q_i$ ；乘以 sin 后，再加上  $q_{\text{rot}} * \cos$ ，就得到上式。这里代码中的 `cos`、`sin` 对应广播后的  $C$ 、 $S$ ，K 的计算相同

```
def rotate_half(x):
    x1 = x[..., : x.shape[-1] // 2]
    x2 = x[..., x.shape[-1] // 2 :]
    return torch.cat((-x2, x1), dim=-1)

def apply_rotary_pos_emb(q, k, cos, sin, unsqueeze_dim=1):
    cos = cos.unsqueeze(unsqueeze_dim)
    sin = sin.unsqueeze(unsqueeze_dim)

    # Keep half or full tensor for later concatenation
    rotary_dim = cos.shape[-1]
    q_rot, q_pass = q[..., :rotary_dim], q[..., rotary_dim:]
    k_rot, k_pass = k[..., :rotary_dim], k[..., rotary_dim:]

    # Apply rotary embeddings on the first half or full tensor
    q_embed = (q_rot * cos) + (rotate_half(q_rot) * sin)
    k_embed = (k_rot * cos) + (rotate_half(k_rot) * sin)

    # Concatenate back to full shape
    q_embed = torch.cat([q_embed, q_pass], dim=-1)
    k_embed = torch.cat([k_embed, k_pass], dim=-1)
    return q_embed, k_embed
```